



INSTITUT TEKNOLOGI DEL

MATERI PRAKTIKUM

4233201 – Kecerdasan Buatan

Semester Genap Tahun Ajaran 2026/2027

Session Date	: 14 September 2026
Week/Session	: 2/3
Topic	: Data Understanding
Practicum Goals	: Mahasiswa mampu melakukan import data serta melakukan eksplorasi data awal
Duration	: 2 x 50 minutes
Place of Submission	: ecourse
Submission Deadline	: Akhir Sesi 2

Import data menggunakan library pandas

```
In [1]: import pandas as pd
path = "GlobalWeatherRepository.csv"
df = pd.read_csv(path)
df
```

```
Out[1]:
```

	country	location_name	latitude	longitude	timezone	last_updated_epoch
0	Afghanistan	Kabul	34.5200	69.1800	Asia/Kabul	171584910
1	Albania	Tirana	41.3300	19.8200	Europe/Tirane	171584910
2	Algeria	Algiers	36.7600	3.0500	Africa/Algiers	171584910
3	Andorra	Andorra La Vella	42.5000	1.5200	Europe/Andorra	171584910
4	Angola	Luanda	-8.8400	13.2300	Africa/Luanda	171584910
...	...	...	...	...	...	...
39589	Venezuela	Caracas	10.5000	-66.9167	America/Caracas	173348280
39590	Vietnam	Hanoi	21.0333	105.8500	Asia/Bangkok	173348100
39591	Yemen	Sanaa	15.3547	44.2067	Asia/Aden	173348190
39592	Zambia	Lusaka	-15.4167	28.2833	Africa/Lusaka	173348190
39593	Zimbabwe	Harare	-17.8178	31.0447	Africa/Harare	173348280

39594 rows × 41 columns



Dari output di atas, dapat diketahui beberapa karakteristik data seperti berikut ini:

1. Data terdiri dari 39594 baris (indeks DataFrame dimulai dari 0 hingga 39593)
2. Terdapat 41 kolom atau atribut dalam data

Eksplorasi selanjutnya yang dapat dilakukan adalah melihat lima data pertama (df.head) dan lima data terakhir (df.tail).

```
In [2]: df.head()
```

Out[2]:

	country	location_name	latitude	longitude	timezone	last_updated_epoch	las
0	Afghanistan	Kabul	34.52	69.18	Asia/Kabul	1715849100	
1	Albania	Tirana	41.33	19.82	Europe/Tirane	1715849100	
2	Algeria	Algiers	36.76	3.05	Africa/Algiers	1715849100	
3	Andorra	Andorra La Vella	42.50	1.52	Europe/Andorra	1715849100	
4	Angola	Luanda	-8.84	13.23	Africa/Luanda	1715849100	

5 rows × 41 columns



In [3]: `df.tail()`

Out[3]:

	country	location_name	latitude	longitude	timezone	last_updated_epoch	las
39589	Venezuela	Caracas	10.5000	-66.9167	America/Caracas	1733482800	
39590	Vietnam	Hanoi	21.0333	105.8500	Asia/Bangkok	1733481000	
39591	Yemen	Sanaa	15.3547	44.2067	Asia/Aden	1733481900	
39592	Zambia	Lusaka	-15.4167	28.2833	Africa/Lusaka	1733481900	
39593	Zimbabwe	Harare	-17.8178	31.0447	Africa/Harare	1733482800	

5 rows × 41 columns



Jika ingin langsung menganalisis data dari kolom temperature, bisa langsung mengambil data temperature di kolom 7 dengan cara berikut.

In [4]: `df_noid = df.iloc[:,7:]`
`df_noid`

Out[4]:

	temperature_celsius	temperature_fahrenheit	condition_text	wind_mph	wind_kph
0	26.6	79.8	Partly Cloudy	8.3	13.3
1	19.0	66.2	Partly cloudy	6.9	11.2
2	23.0	73.4	Sunny	9.4	15.1
3	6.3	43.3	Light drizzle	7.4	11.9
4	26.0	78.8	Partly cloudy	8.1	13.0
...	...	...	...	...	...
39589	16.2	61.2	Sunny	4.0	6.5
39590	21.2	70.2	Partly cloudy	9.6	15.5
39591	22.2	71.9	Sunny	9.4	15.1
39592	36.0	96.8	Sunny	4.9	7.9
39593	34.7	94.4	Sunny	6.5	10.4

39594 rows × 34 columns



Untuk memahami data dari ringkasan statistik, DataFrame menyediakan fungsi describe().

In [5]: `df_noid.describe()`

Out[5]:

	temperature_celsius	temperature_fahrenheit	wind_mph	wind_kph	wind_degr
count	39594.000000	39594.000000	39594.000000	39594.000000	39594.0000
mean	24.350599	75.832651	8.341135	13.427714	172.6308
std	8.130323	14.634566	10.624011	17.097136	101.8200
min	-21.900000	-7.400000	2.200000	3.600000	1.0000
25%	20.200000	68.400000	4.300000	6.800000	88.0000
50%	26.100000	79.000000	7.200000	11.500000	168.0000
75%	29.200000	84.600000	11.600000	18.700000	258.0000
max	49.200000	120.600000	1841.200000	2963.200000	360.0000

8 rows × 27 columns



- count menunjukkan jumlah total data atau observasi dalam kolom tersebut
- mean adalah nilai rata-rata aritmetik dari seluruh data pada kolom
- std (standar deviasi) mengukur seberapa besar variasi atau penyebaran data dari nilai rata-rata
- min menyatakan data terkecil pada kolom
- 25% menunjukkan kuartil pertama (Q1) dari data pada kolom
- 50% menunjukkan titik tengah data (median) atau kuartil kedua (Q2) dari data pada kolom
- 75% menyatakan kuartil ketiga (Q3) dari data pada kolom
- max menyatakan data maksimum atau terbesar dari data pada kolom

Dari data temperature_celsius, bisa disimpulkan bahwa suhu terendah ada di -21.9 dan maksimum suhu di 49.2 yang berarti rentang suhu cukup besar. Dengan rata-rata suhu 24.350599 dan simpangan baku 8.130323, menunjukkan bahwa suhu bervariasi secara signifikan. Q1, Q2, dan Q3, menunjukkan distribusi suhu dengan separuh data berkisar antara 20.2 hingga 29.2 derajat celsius.

Jika hanya ingin mengetahui data rata-rata tekanan udara dan kelembaban udara saja, bisa dengan menggunakan cara berikut ini.

```
In [6]: df_noid[['pressure_mb', 'humidity']].mean()
```

```
Out[6]: pressure_mb    1013.195914  
humidity      62.528237  
dtype: float64
```

Jika ingin mengetahui hubungan atau korelasi antar data, bisa dengan menggunakan fungsi `corr()`.

Nilai korelasi berkisar dari -1 hingga 1.

- 1 korelasi positif (ketika satu variabel naik, yang lain ikut naik)
- -1 korelasi negatif (ketika satu variabel naik, yang lain turun)
- 0 berarti tidak ada korelasi

```
In [7]: df_noid[['temperature_celsius', 'humidity', 'air_quality_Ozone']].corr()
```

```
Out[7]:
```

	temperature_celsius	humidity	air_quality_Ozone
temperature_celsius	1.000000	-0.420825	0.334880
humidity	-0.420825	1.000000	-0.508499
air_quality_Ozone	0.334880	-0.508499	1.000000

Dari data di atas, dapat dipahami bahwa:

- Temperature vs Air Quality Ozone (+0.334880), berarti semakin naik suhu maka kadar ozon juga meningkat.
- Humidity vs Air Quality Ozone (-0.508499), berarti semakin naik kelembaban udara maka kadar ozon menurun.
- Kesimpulan: kenaikan suhu meningkatkan kadar ozon, sedangkan kenaikan kelembaban udara menurunkan kadar ozon.

Tugas!

1. Ikuti langkah-langkah pada modul ini, kemudian analisa korelasi antara temperature_fahrenheit, pressure_mb, dan air_quality_Sulphur_dioxide.
2. Gunakan dataset <https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset>
 - Analisa mean, std, min, max, Q1, Q2, Q3 untuk data Previous Purchases
 - Analisa korelasi Age vs Purchase Amount (USD) dan Purchase Amount (USD) vs Review Rating